Plano de MLOps: Monitoramento Contínuo, Detecção de Drifts e Ciclo de Vida Preditivo

Empresa: AeroMotion Dynamics S.A.
Divisão: Turbinas & Propulsão de Alta Precisão
Equipamentos Monitorados: Bancadas de Testes de Desenvolvimento (TURB-101 a TURB-104)
Ciclo Operacional: Janela de 12 meses contínuos
Versão do Documento: 1.0.0

---

1. Sumário Executivo e Objetivos de Engenharia

O presente plano estabelece a governança de Machine Learning Operations (MLOps) para o sistema preditivo de falhas e detecção de anomalias implementado nas quatro bancadas de testes de turbinas industriais da AeroMotion Dynamics.

Operando em ambiente fabril crítico, os modelos preditivos supervisionados (`LGBMClassifier`) e não supervisionados (`IsolationForest`) estão sujeitos a fenômenos de degradação temporal decorrentes de:

1. Descalibração e envelhecimento natural de transdutores físicos (*Data Drift*).
2. Reformas estruturais, variações nas ligas metálicas de pás de rotor e novos perfis dinâmicos de rotação (*Concept Drift*).
3. Ruídos impulsivos e flutuações de interferência eletromagnética (EMI) no ambiente operacional de ensaios.

O objetivo deste plano é assegurar que a taxa de acerto diagnóstica permaneça acima do patamar crítico de **Recall** $\geq 90\%$ para todas as classes de falha ao longo de um horizonte operacional de 12 meses.

---

2. Arquitetura do Sistema e Topologia de Deploy

A inferência preditiva é descentralizada em nós de *Edge Computing* acoplados diretamente ao ambiente de automação industrial (CLP/SCADA) através de contêineres Docker executando microsserviços FastAPI:

```
[Bancadas TURB-101 a 104]
          │ (Sensores IoT - 10 min)
          ▼
[Gateway OT / CLP / SCADA]
          │ (mTLS / REST)
          ▼
[Nó Edge: Docker Container]
    ├── FastAPI (Pydantic Schema Validation)
    ├── Pré-processamento & Feature Engineering (Rolling 1h/6h, Severidade
Dinâmica)
    ├── Scaler Normalizador (RobustScaler)
    └── Modelos Ativos (LGBMClassifier + Isolation Forest)
          │
          ├──► [Alarme SCADA / Intervenção Humana]
```

```
            │
            └──► [Broker MQTT / S3 Data Lake] ──► [Pipeline de MLOps / Retreino
Central]
```

---

3. Estratégia de Monitoramento e Mitigação de Data Drift

O *Data Drift* ocorre quando a distribuição estatística das covariáveis de entrada se altera ($P(X_t) \neq P(X_0)$), mesmo que as relações físicas de falha ainda não tenham mudado substancialmente.

3.1. Variáveis Monitoradas e Limites Físicos Operacionais

Todas as variáveis brutas e sintetizadas são auditadas em tempo real e em janelas móveis:

Variável	Faixa Nominal	Faixa Limite Físico	Frequência de Avaliação
`temperatura_mancal_c`	45.0°C a 85.0°C	0.0°C a 150.0°C	Em cada leitura (10 min)
`vibracao_rms_mms`	1.0 a $4.5\ \text{mm/s}$	0.0 a $25.0\ \text{mm/s}$	Em cada leitura (10 min)
`pressao_oleo_bar`	3.5 a $5.2\ \text{Bar}$	0.5 a $10.0\ \text{Bar}$	Em cada leitura (10 min)
`rotacao_rpm`	2300 a $3600\ \text{RPM}$	500 a $5000\ \text{RPM}$	Em cada leitura (10 min)
`emissao_acustica_db`	40.0 a $68.0\ \text{dB}$	20.0 a $100.0\ \text{dB}$	Em cada leitura (10 min)
`corrente_eletrica_amp`	18.0 a $42.0\ \text{A}$	5.0 a $60.0\ \text{A}$	Em cada leitura (10 min)
`severidade_dinamica`	0.0003 a 0.0018	0.0 a 0.05	Em cada leitura (10 min)

3.2. Testes Estatísticos Formais de Desvio

A cada 15 e 30 dias de operação, os dados agregados das bancadas são submetidos a testes formais contra o *baseline* de validação (primeiros 70% cronológicos):

A. Teste de Kolmogorov-Smirnov (KS-Test)

Aplicado individualmente a cada sensor contínuo para quantificar a distância máxima entre a distribuição empírica atual $F_t(x)$ e a distribuição de referência $F_0(x)$:

$$D_{KS} = \sup_x |F_t(x) - F_0(x)|$$

- **P-valor** > 0.05: Distribuição estável. Operação nominal mantida.
- $0.01 \leq \text{P-valor} \leq 0.05$: Aviso de desvio instrumental moderado. Sinalizar ordem de serviço para verificação instrumental.
- **P-valor** < 0.01: Alerta crítico de *Data Drift*. Disparo obrigatório de recalibração de sensores e análise da bancada.

B. Population Stability Index (PSI)

Calculado para avaliar o deslocamento populacional multivariado em baldes (*bins*) percentílicos:

$$PSI = \sum_{k=1}^{K} (P_{t,k} - P_{0,k}) \times \ln\left(\frac{P_{t,k}}{P_{0,k}}\right)$$

Onde $P_{0,k}$ representa a fração percentual de amostras do *baseline* no intervalo k, e $P_{t,k}$ a fração na janela atual sob análise.

- $PSI < 0.10$: Sem alteração significativa; nenhuma ação requerida.
- $0.10 \leq PSI < 0.25$: Deslocamento moderado; intensificar frequência de validação dos laudos manuais.
- $PSI \geq 0.25$: Deslocamento populacional severo; bloqueio do modelo corrente e acionamento de retreinamento.

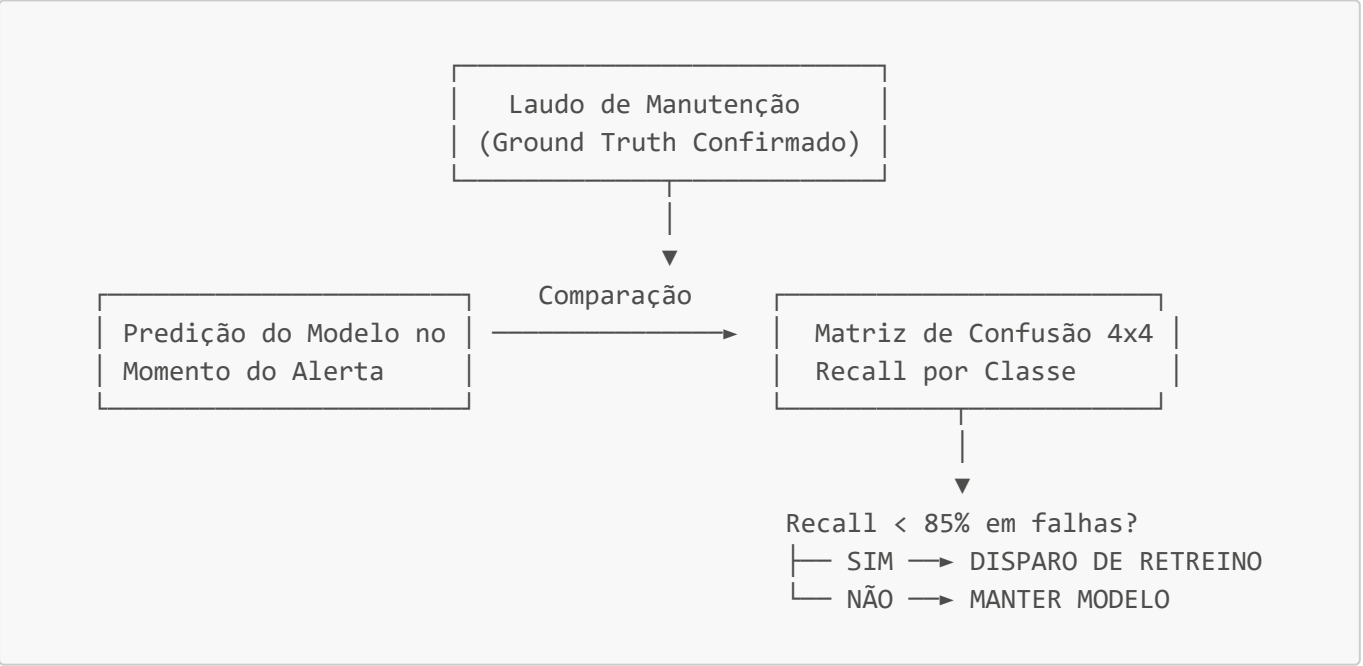
---

4. Estratégia de Monitoramento e Mitigação de Concept Drift

O *Concept Drift* ocorre quando a relação matemática entre a telemetria dos sensores e os modos reais de falha mecânica se transforma ($P(Y|X_t) \neq P(Y|X_0)$). Na indústria aeronáutica, isso costuma decorrer de fadiga estrutural não modelada ou modificações de projeto mecânico nas pás.

4.1. Indicadores Chave de Desempenho (KPIs) Contínuos

A performance dos modelos é avaliada mensalmente a partir dos laudos de manutenção emitidos pelos técnicos pós-inspeção:



4.2. Matriz de Tolerância e Gatilhos de Ação

Métrica / Diagnóstico	Meta Operacional	Limiar de Alerta	Gatilho de Ação Crítica
Recall (Desgaste de Rolamento)	$\geq 90.0\%$	$< 88.0\%$	$< 85.0\%$ (Retreino Imediato)

Métrica / Diagnóstico	Meta Operacional	Limiar de Alerta	Gatilho de Ação Crítica
Recall (Desbalanceamento de Rotor)	$\geq 90.0\%$	$< 88.0\%$	$< 85.0\%$ (Retreino Imediato)
Recall (Cavitação / Superaquecimento)	$\geq 92.0\%$	$< 90.0\%$	$< 87.0\%$ (Retreino Imediato)
F1-Score Macro Global	$\geq 90.0\%$	$< 87.0\%$	$< 84.0\%$ (Retreino Imediato)
Falsos Positivos do Isolation Forest	$\leq 4.0\%$	$> 6.0\%$	$> 8.0\%$ (Recalibração do Limiar)

5. Pipeline Automatizado de Retreinamento e Promoção

Quando um gatilho de retreino é ativado por desvio de dados ou conceito, o fluxo de engenharia executa o seguinte protocolo:

```
[Início: Trigger]
       │
       ▼
1. Extração da Janela Histórica Deslizante (Últimos 6 meses)
       │
       ▼
2. Execução do Pré-processador Industrial (Filtros EMI + Interpolação
Spline/Temporal)
       │
       ▼
3. Síntese de Features (Janelas Móveis 1h/6h + Severidade Dinâmica)
       │
       ▼
4. Particionamento Temporal Cronológico (70% Treino / 30% Validação)
       │
       ▼
5. Reamostragem com SMOTE (Exclusivamente no conjunto de treino)
       │
       ▼
6. Otimização de Hiperparâmetros (RandomizedSearchCV - Foco em Recall Macro)
       │
       ▼
7. Avaliação em Shadow Deployment (15 dias operando em paralelo no Edge)
       │
       ▼
   Aprovado nos Critérios de Aceite?
   ├── SIM ──► Promoção para Produção (models/classifier_model.joblib)
   └── NÃO ──► Rollback para Última Versão Estável e Notificação da Engenharia
```

5.1. Critérios Estritos de Aceite para Promoção

O novo modelo candidato só substitui o modelo em produção se cumprir simultaneamente:

1. $\text{Recall Macro}_{\text{candidato}} > \text{Recall Macro}_{\text{atual}}$.
2. Recall individual em cada uma das classes de falha $(1, 2, 3) \geq 90.0\%$.
3. Latência de inferência no nó Edge $\leq 25\ \text{ms}$ para o endpoint `POST /predict`.
4. Sem exceções de validação no esquema Pydantic para o conjunto de testes de regressão.

---

6. Versionamento, Registro de Modelos e Linhagem de Dados

Para assegurar reprodutibilidade e conformidade regulatória:

- **Nomenclatura Semântica**: Modelos persistidos seguem o padrão `vMAJOR.MINOR.PATCH`:
  - *MAJOR*: Mudança na arquitetura de atributos (ex.: nova inclusão de sensores físicos).
  - *MINOR*: Retreinamento motivado por *Concept Drift* ou novos hiperparâmetros.
  - *PATCH*: Ajustes finos de calibração instrumental ou atualização do `scaler.joblib`.
- **Contrato de Features**: O arquivo serializado `models/feature_names.joblib` é acoplado obrigatoriamente a cada modelo, garantindo que o vetor de entrada recebido pelo endpoint FastAPI mantenha exata conformidade dimensional e tipológica.
- **Linhagem (Data Lineage)**: Cada artefato gerado registra o *hash* SHA-256 do dataset de origem, garantindo rastreabilidade perante auditorias de qualidade aeroespacial.

---

7. Cronograma Operacional e Matriz RACI (12 Meses)

A governança do plano é distribuída ao longo dos 12 meses de acompanhamento:

```
Mês 01 ⟶ Validação de Estabilidade Inicial e Baseline Instrumental
Mês 03 ⟶ Auditoria Trimestral de Calibração e Cálculo de KS-Test
Mês 06 ⟶ Revisão Semestral de Desempenho e Reavaliação do Isolation Forest
Mês 09 ⟶ Simulação de Injeção de Falhas Sintéticas e Teste de Resiliência
Mês 12 ⟶ Auditoria Completa de Ciclo Anual, Retreino Geral e Fechamento de Laudo
```

Matriz de Responsabilidade (RACI)

Atividade	Engenheiro de MLOps	Cientista de Dados	Técnico de Bancada	Gestor de Qualidade
Monitoramento de KS-Test e PSI	**R / A**	**C**	**I**	**I**
Validação de Laudo de Falha Real	**I**	**I**	**R**	**A**
Execução do Pipeline de Retreino	**R**	**A**	**I**	**I**
Validação de Shadow Deployment	**R**	**C**	**C**	**A**

Atividade	Engenheiro de MLOps	Cientista de Dados	Técnico de Bancada	Gestor de Qualidade
Promoção e Deploy no Edge Docker	**R / A**	**I**	**I**	**I**

*Legenda: **R** = Responsável pela execução; **A** = Aprovador final; **C** = Consultado; **I** = Informado.*